



Propuesta de Redes neuronales aplicadas a problemas de transporte público en la ciudad de Manizales

JULIÁN DAVID PULGARÍN PIRAZÁN

Universidad Nacional de Colombia
Facultad de Administración, Departamento de Informática y Computación
Manizales, Colombia
2023

Propuesta de Redes neuronales aplicadas a problemas de transporte público en la ciudad de Manizales

JULIÁN DAVID PULGARÍN PIRAZÁN

Trabajo de grado presentado como requisito parcial para optar al título de:

Administrador(a) de Sistemas Informáticos

Director(a):

PhD. Ingeniería y Néstor Darío Duque Méndez

Modalidad del trabajo de grado:

Trabajos investigativos – Trabajo monográfico

Universidad Nacional de Colombia

Facultad de Administración, Departamento de Informática y Computación

Manizales, Colombia

2023

A mis padres

"Comienza el día como si fueras a encontrarte con la ignorancia y la necesidad en cada paso: así siempre te moverás con la precaución y te alegrarás del conocimiento."

Marco Aurelio. (II d.C.)

Agradecimientos

Quiero expresar mi profundo agradecimiento a mis padres, quienes han sido mi fuente inagotable de amor, apoyo y sabiduría a lo largo de mi vida. Gracias a su dedicación y guía, he aprendido valores fundamentales que han moldeado mi carácter y mi visión del mundo. También quiero reconocer el invaluable papel de todos mis profesores, cuyo conocimiento, paciencia y dedicación han iluminado mi camino educativo. Cada lección, cada consejo y cada corrección han sido piedras angulares en mi crecimiento intelectual y personal. Estoy eternamente agradecido por el inmenso regalo de la educación que me han brindado mis padres y maestros; es un tesoro que llevaré conmigo toda mi vida.

Resumen

Propuesta de Redes neuronales aplicadas a problemas de transporte público en la ciudad de Manizales

La problemática del transporte público es un tema que afecta a gran parte de la población, especialmente a aquellas personas que dependen de él para desplazarse diariamente a sus trabajos, estudios y otros compromisos. La falta de eficiencia en este servicio se traduce en retrasos, sobrecarga de pasajeros, accidentes, entre otros inconvenientes. La inteligencia artificial (IA) es un campo en constante evolución que ha mostrado resultados prometedores en la solución de problemas complejos. En particular, las redes neuronales son una técnica de IA que se ha utilizado con éxito en diversas áreas, desde la medicina hasta la ingeniería. Se plantea la utilización de técnicas de IA, específicamente redes neuronales, para abordar la problemática del transporte público en la ciudad de Manizales;” El Tiempo. (2018). El incierto futuro de la movilidad en la ciudad de Manizales”. En la ciudad de Manizales en la actualidad se presenta un aumento significativo en el número de vehículos por persona, lo cual genera un mayor congestionamiento en horas pico en las vías principales de la ciudad, este problema se intensifica cuando las entidades prestadoras del servicio de transporte público no tienen un buen manejo de diferentes variables que pueden llegar a tener consecuencias positivas o negativas de acuerdo a la debida coordinación de dichas variables tales como lo son: El número de vehículos de transporte público en circulación, teniendo en cuenta la hora y demanda del servicio, las horas de más y menos afluencia de usuarios, los destinos con mayor demanda de vehículos; estas variables abren la incógnita de si la IA puede ayudar a mitigar los efectos adversos con ayuda de un buen procesamiento de toda la información disponible y una técnica de IA que nos ayude a gestionar toda esta información para realizar posibles predicciones.

Palabras clave: (Mínimo 3 y máximo 7 palabras, preferiblemente use lenguaje técnico-científico).

Abstract

Proposal of Neural Networks Applied to Public Transportation Issues in the City of Manizales

La issue del transporte público is a topic that affects a large part of the population, especially those people who depend on it for their daily commutes to work, school, and other commitments. The lack of efficiency in this service results in delays, overcrowding, accidents, among other inconveniences. Artificial intelligence (AI) is a constantly evolving field that has shown promising results in solving complex problems. In particular, neural networks are an AI technique that has been successfully used in various areas, from medicine to engineering. The use of AI techniques, specifically neural networks, to address the issue of public transportation in the city of Manizales is proposed; "El Tiempo. (2018). The uncertain future of mobility in the city of Manizales". In the city of Manizales, there is currently a significant increase in the number of vehicles per person, which generates greater congestion during peak hours on the city's main roads. This problem intensifies when the entities providing public transportation services do not have good management of different variables that can have positive or negative consequences depending on the proper coordination of these variables, such as: the number of public transportation vehicles in circulation, taking into account the time and demand for the service, the hours of highest and lowest user traffic, and the destinations with the highest demand for vehicles. These variables raise the question of whether AI can help mitigate adverse effects with the assistance of proper processing of all available information and an AI technique that helps manage all this information to make possible predictions.

Keywords: (Mínimo 3 y máximo 7 palabras, preferiblemente use lenguaje técnico-científico).

Contenido

	Pág.
Resumen	VII
Lista de figuras.....	X
Lista de tablas	XI
Lista de símbolos y abreviaturas	XII
Introducción.....	1
1. Presentación del trabajo de grado	3
1.1 Planteamiento del problema o situación abordada	3
1.2 Objetivo general	4
1.3 Objetivos específicos	4
1.4 Metodología	4
1.4.1 Procedimiento.....	
1.5 Ejemplo de presentación y citación de figuras, tablas y cuadros	Error!
Bookmark not defined.	
2. Revisión de literatura.....	15
2.1 Antecedentes.....	
3. Desarrollo	19
3.1 Marco conceptual	
4. Conclusiones y recomendaciones.....	25
4.1 Conclusiones.....	25
4.2 Recomendaciones.....	25
A. Anexo: Nombrar el anexo A de acuerdo con su contenido.....	27
Bibliografía	29

Lista de figuras

Pág.

Figura 2-1: Tipos y parte del fruto de palma de aceite. **Error! Bookmark not defined.**

Nota: Si es requerido, se pueden incluir lista de ilustraciones, graficas, diagramas, dibujos o fotografías. Tenga presente que estas lista deben ser generadas de forma automatizada utilizando las opciones que proporciona el software de procesamiento de texto.

Lista de tablas

Pág.

Tabla 2-1: Participación de las energías renovables primaria..... **Error! Bookmark not defined.**

Nota: Si es requerido, se puede incluir la lista de cuadros, en caso que se utilicen en el desarrollo de la tesis o trabajo de investigación. Tenga presente que estas lista deben ser generadas de forma automatizada utilizando las opciones que proporciona el software de procesamiento de texto.

Lista de símbolos y abreviaturas

Esta sección es opcional, dado que existen disciplinas que no manejan símbolos y/o abreviaturas. Se incluyen símbolos generales (con letras latinas y griegas), subíndices, superíndices y abreviaturas (incluir sólo las clases de símbolos que se utilicen). Cada una de estas listas debe estar ubicada en orden alfabético de acuerdo con la primera letra del símbolo (en esta plantilla, el título del tipo de símbolo está en letra Arial de 14 puntos y en negrilla). Para escribir la definición en las tablas, se puede usar la herramienta de referencia cruzada (para textos editados en Microsoft Word). A continuación, se presentan algunos ejemplos.

Símbolos con letras latinas

Símbolo	Término	Unidad SI	Definición
A	Área	m^2	$\iint dx dy$
A_{BET}	Área interna del sólido	$\frac{m^2}{g}$	ver DIN ISO 9277
A_g	Área transversal de la fase gaseosa	m^2	Ec. 3.2
A_s	Área transversal de la carga a granel	m^2	Ec. 3.6
a	Coeficiente	1	Tabla 3-1

Símbolos con letras griegas

Símbolo	Término	Unidad SI	Definición
α_{BET}	Factor de superficie	$\frac{m^2}{g}$	$(w_{F,waf})(A_{BET})$
β_i	Grado de formación del componente i	1	$\frac{m_j}{m_{bm} \varphi}$
γ	Wandhaufwinkel (Stahlblech)	1	Sección 3.2
ε	Porosidad de la partícula	1	$1 - \frac{\rho_s}{\rho_w}$
H	mittlere Bettneigungswinkel (Stürzen)	1	Figura 3-1

Subíndices

Subíndice	Término
Bm	Materia orgánica
DR	Dubinín-Radushkevich
E	Experimental

Superíndices

Superíndice	Término
-------------	---------

N	Exponente, potencia
---	---------------------

Abreviaturas

Abreviatura	Término
-------------	---------

1.LT	Primera ley de la termodinámica
------	---------------------------------

DF	Dimension fundamental
----	-----------------------

RFF	Racimos de fruta fresca
-----	-------------------------

Introducción

La En la actualidad, el transporte público en la ciudad de Manizales enfrenta un desafío constante debido al aumento exponencial de vehículos en las calles, lo que resulta en congestión vehicular y problemas en la operación de las empresas encargadas de prestar este servicio. La gestión ineficiente de diversas variables operativas es uno de los principales desafíos a abordar. Esta problemática impide que se aproveche la gran cantidad de información generada diariamente en la industria del transporte público, lo que podría utilizarse para realizar predicciones y optimizaciones. Este trabajo se enfoca en explorar cómo la implementación de una red neuronal puede beneficiar al transporte público en Manizales al permitir la generación de predicciones basadas en datos históricos y variables relevantes. La inteligencia artificial, en particular las redes neuronales, ofrece la capacidad de procesar y analizar grandes volúmenes de datos para extraer patrones y tendencias, lo que podría llevar a un mejor entendimiento de la operación del sistema de transporte público. El objetivo general de este trabajo es proponer un modelo de predicción de diferentes variables del sistema de transporte público en Manizales mediante la aplicación de redes neuronales. Para lograr este objetivo, se llevarán a cabo las siguientes etapas: recopilación y análisis de datos, selección de variables relevantes, diseño y desarrollo de la arquitectura de la red neuronal, validación en un ambiente de prueba y análisis de resultados con recomendaciones para el sistema de transporte público. Esta investigación se justifica por la necesidad de optimizar el transporte público en una ciudad con topografía accidentada como Manizales. Además, la aplicación de técnicas de inteligencia artificial, como las redes neuronales, podría ayudar a prevenir problemas operativos y mejorar la seguridad de los usuarios. La implementación de inteligencia artificial en el transporte público no solo beneficia a los usuarios, sino que también impacta positivamente en la sociedad en general, mejorando la eficiencia, reduciendo costos y previniendo incidentes.

1. Presentación del trabajo de grado

Este trabajo de grado tiene como objetivo principal abordar el desafío del transporte público en la ciudad de Manizales mediante la implementación de técnicas de inteligencia artificial, específicamente las redes neuronales. La problemática del congestionamiento vehicular y la mala gestión de variables operativas en el transporte público se han convertido en obstáculos significativos para una operación eficiente y satisfactoria para los usuarios. En este contexto, se presenta una propuesta sólida para utilizar datos históricos y variables relevantes en la operación del transporte público para entrenar una red neuronal. Esta red neuronal se diseñará meticulosamente, considerando la arquitectura de las capas ocultas, la función de activación y otros parámetros cruciales para garantizar precisión en las predicciones. La aplicación de esta tecnología permitirá no solo prever tendencias y patrones, sino también optimizar rutas y recursos, mejorando así la calidad del servicio ofrecido a los ciudadanos. La importancia de este estudio radica en su capacidad para transformar datos crudos en conocimientos procesables, proporcionando a las autoridades locales y a las empresas de transporte público información valiosa para tomar decisiones informadas. Este trabajo se presenta como una contribución al campo de la optimización del transporte público, y se espera que sus hallazgos y recomendaciones puedan ser aplicados en el contexto más amplio de las ciudades con desafíos similares en todo el mundo.

1.1 Planteamiento del problema o situación abordada

¿Cómo puede beneficiar al transporte público en la ciudad de Manizales la implementación de una red neuronal para generar posibles predicciones?

1.2 Objetivo general

Realizar una propuesta de predicción de diferentes variables del sistema de transporte público en Manizales aplicando redes neuronales

1.3 Objetivos específicos

- Recopilar y analizar la información disponible sobre el sistema de transporte público en este caso de la ciudad de Manizales, Caldas, incluyendo datos históricos de operación y variables relevantes para la predicción.
- Seleccionar las variables más relevantes a partir de la información recopilada y definir el modelo de red neuronal adecuado para la predicción.
- Diseñar y desarrollar una propuesta o un modelo de arquitectura de la red neuronal utilizando herramientas y lenguajes de programación especializados en inteligencia artificial.
- Validar la red neuronal en un ambiente de prueba para comprobar su funcionalidad y eficacia en la predicción de las variables seleccionadas.
- Analizar los resultados obtenidos y proponer recomendaciones para el sistema de transporte público.

1.4 Metodología

Se utilizará un enfoque mixto, este enfoque combina elementos de los enfoques cuantitativo y cualitativo, permitiendo la recolección y análisis de datos tanto cuantitativos como cualitativos. Para la implementación del modelo, se utilizarán herramientas y el lenguaje de programación Python. Se considerarán posibles problemas durante el desarrollo del modelo y se buscarán soluciones adecuadas en caso de ser necesario.

Los objetivos específicos planteados en esta propuesta se alcanzarán a través de la serie de pasos que se mencionan a continuación:

- Revisión bibliográfica: se realizará una revisión bibliográfica exhaustiva de los antecedentes relacionados con la aplicación de técnicas de inteligencia artificial en el mejoramiento de sistemas de transporte público.

- Recopilación de datos: se recopilarán datos relevantes cuyos aspectos estén directamente relacionados con las problemáticas inherentes al transporte público de Manizales. Esto implica recopilar datos específicos que permitan comprender y abordar las dificultades particulares que enfrenta el sistema de transporte en la ciudad.
- Preprocesamiento de datos: se realizará un preprocesamiento de los datos para limpiarlos y transformarlos en un formato adecuado para su uso en el modelo de redes neuronales.
- Desarrollo del modelo de redes neuronales: se desarrollará un modelo de redes neuronales para predecir diferentes variables del sistema de transporte público, como la demanda de pasajeros, la eficiencia de la ruta de los autobuses, entre otras.
- Validación del modelo: se llevará a cabo una validación del modelo utilizando técnicas de validación cruzada para asegurar su fiabilidad y precisión.
- Análisis e interpretación de resultados: Se analizarán e interpretarán los resultados obtenidos para identificar patrones y tendencias relevantes en el sistema de transporte público.
- Presentación de resultados: se analizarán los resultados obtenidos del modelo y se presentarán en un informe final.
- Propuesta de mejoras: Con base en los resultados y el análisis realizado, se propondrán mejoras al sistema de transporte público para su optimización.

1.4.1 Procedimiento

Aplicación de Data Augmentation en el Conjunto de Datos

El proceso de Data Augmentation es crucial en la mejora y diversificación de la información disponible. En este caso de estudio, como se mencionó anteriormente el conjunto de datos está compuesto por las variables: hora, ruta, número de vehículos por ruta, condiciones de la ruta, y día de la semana, para capturar la variabilidad en la demanda de pasajeros, se ha asignado un valor numérico a la demanda: 3 para alta demanda, 2 para demanda "media" y 1 para una demanda baja de usuarios (tabla 5), La inclusión de diferentes niveles de demanda (alta, media y baja) permite a el modelo comprender mejor los patrones de

comportamiento asociados con diferentes niveles de necesidad de los usuarios. Esta representación detallada de la demanda proporciona a la red neuronal una perspectiva más matizada y ajustada a la realidad del sistema, lo que, a su vez, mejora la capacidad de la red para generalizar y hacer predicciones precisas. Se utilizaron técnicas de Data Augmentation para crear variaciones y expandir el conjunto de datos, lo que a su vez mejora la capacidad de la red neuronal para generalizar y hacer predicciones precisas.

Tabla 5: Categorización de demanda

<i>demanda</i>	
<i>alta</i>	3
<i>media</i>	2
<i>baja</i>	1

En el caso de la hora del día laboral de los vehículos de servicio público se aplicó rotación temporal para variar las horas del día. Esta técnica crea nuevas instancias de datos ajustando la hora en un rango específico, lo que permite a la red neuronal aprender diferentes patrones temporales, se tienen en cuenta las horas pico las cuales implican un nivel mayor de demanda de pasajeros en el servicio de transporte público; En particular se tomaron en cuenta todas las horas del día en las que los vehículos están disponibles para los usuarios y se exploraron todas las posibles combinaciones de las variables clave que se están estudiando en el actual caso de estudio. La variación en las horas del día se gestionó mediante la técnica conocida como rotación temporal mencionada anteriormente, que permitió ajustar las horas dentro de un rango específico (5:00-22:00). Es fundamental mencionar que, al generar estas nuevas instancias de datos, se preservó la integridad de la información original. Cada nueva combinación de variables se creó de manera coherente y realista, manteniendo la relevancia y validez de los datos para el análisis. Además, este enfoque permitió explorar una amplia gama de situaciones posibles, enriqueciendo así la comprensión del comportamiento del sistema de transporte público sin comprometer la calidad ni la integridad de los datos originales.

En primer lugar, se reconoce la importancia de comprender el sistema de transporte público a lo largo del día. Cada hora del día puede presentar variaciones significativas en la demanda y en las condiciones de las rutas, desde las horas pico hasta las horas de menos congestión. Al abordar todas estas horas del día, se busca capturar la complejidad

de los patrones de comportamiento que surgen en diferentes momentos, reflejando así situaciones que podrían surgir naturalmente en el sistema de transporte público en la ciudad de Manizales. No se ha alterado ni distorsionado la naturaleza fundamental de los datos originales; en su lugar, se ha ampliado el espectro de escenarios posibles para enriquecer la comprensión del comportamiento del sistema. Cabe resaltar que se utilizó el formato de 24 horas en primera instancia para representar cada hora del día y se clasificaron según la demanda de pasajeros estimada relacionando el número “3” con una alta demanda, el número “2” con una demanda moderada y el número “1” con una demanda baja esto se puede apreciar mejor en la Tabla 1.

Tabla 1: Rango de hora

<i>hora</i>	<i>Demanda</i>
6:00 - 8:00	3
8:00-10:00	1
10:00-14:00	2
14:00-17:00	1
17:00-19:00	3
19:00-21:00	2
21:00-22:00	1

En cuanto a el día de la semana se aplicó una rotación del día de la semana, al rotar los días de la semana, se generan instancias que reflejan diferentes comportamientos a lo largo de la semana. Esto es esencial para capturar tendencias semanales y adaptar el modelo a patrones específicos de ciertos días, es común que la demanda de transporte público varíe significativamente entre días laborables y fines de semana. Al rotar los días de la semana, se le permite al modelo distinguir entre patrones de uso diario y aquellos asociados con actividades de ocio y descanso. Se puede complementar con horas específicas cuando la demanda alcanza su punto máximo, al rotar los días, el modelo puede capturar mejor estas horas pico y adaptar las predicciones para acomodar estas variaciones temporales, En situaciones del mundo real, hay días en los que la demanda de transporte público puede ser excepcionalmente baja o incluso nula. Estos días sin demanda pueden deberse a feriados, condiciones climáticas extremas o eventos especiales que afectan el comportamiento del usuario. La capacidad del modelo para reconocer días o incluso horas sin demanda es valiosa para las operaciones del servicio

de transporte público. Las empresas pueden optimizar la asignación de recursos (por ejemplo, vehículos y personal) en días de baja demanda, lo que puede conducir a ahorros significativos, para el caso de estudio se tomaron todos los días de la semana y se categorizaron tomando como referencia la demanda estimada tal como se puede apreciar en la tabla 2. Cabe resaltar que el número “3” se asocia con alta demanda, el “2” a media y el “1” a baja demanda de usuarios.

Tabla 2: Días/demanda

<i>Día</i>	<i>Demanda</i>
<i>Lunes</i>	3
<i>Martes</i>	3
<i>Miercoles</i>	3
<i>Jueves</i>	3
<i>Viernes</i>	3
<i>Sabado</i>	1
<i>Domingo</i>	1

En el caso de la ruta y de los vehículos de servicio de transporte público disponibles por rutas se procedió a ver en las páginas oficiales de las empresas prestadoras del servicio de transporte público cuantos vehículos están a disposición de los usuarios para cada ruta, primeramente se tomaron los sitios donde se despachan las busetas (Control de busetas) y se asociaron con su destino final con el fin de asociar la ruta con un número identificador, se generaron nuevas rutas modificando ligeramente las rutas existentes, se tomaron rutas inversas para las rutas existentes. Por ejemplo, si la Ruta A va de A a B, la ruta invertida irá de B a A. Esto duplica el número de rutas para el análisis, también se utilizaron técnicas de interpolación para crear rutas adicionales entre las rutas existentes. Esto implica la creación de rutas intermedias que sigan un patrón lógico entre las rutas conocidas. Por ejemplo, si se tiene la ruta A y B, se puede crear una nueva ruta C que se encuentre a medio camino entre A y B. generando dos rutas nuevas; puntualmente en el servicio de transporte de la ciudad de Manizales se tomaron 20 rutas de las empresas de servicio de transporte público de la ciudad (Tabla 3), y se le aplicaron las técnicas de Data Augmentation mencionadas anteriormente para generar un total de 40 rutas basadas en el entendimiento profundo de la geografía y la lógica del transporte público en la ciudad de Manizales, cada nueva ruta generada tiene sentido en el contexto del sistema de transporte

público existente. Integrar estas técnicas de aumento de datos ayudo a enriquecer significativamente el conjunto de datos y proporcionar un mayor numero de registros para entrenar la red neuronal.

Tabla 3: Rutas iniciales /vehiculos disponibles por ruta

<i>Ruta</i>	<i>Origen</i>	<i>Destino</i>	<i>Demanda</i>	<i>Ruta</i>	<i>Origen</i>	<i>Destino</i>	<i>Demanda</i>	<i>#Veh_Dis</i>
1	SENA	Chipre	3	21	Chipre	SENA	3	3
2	La linda	Centro	2	22	Centro	La linda	2	3
3	Cumbre	Cambulos	1	23	Cambulos	Cumbre	1	1
4	Aranjuez	Villa Pilar	2	24	Villa Pilar	Aranjuez	2	1
5	Sultana	Villa Pilar	2	25	Villa Pilar	Sultana	2	1
6	Puerta Del Sol	Malteria	3	26	Malteria	Puerta Del Sol	3	2
7	Comuneros	Villa Pilar	1	27	Villa Pilar	Comuneros	1	1
8	Villa Luz	Villa Pilar	2	28	Villa Pilar	Villa Luz	2	1
9	Bengala	Villa Pilar	2	29	Villa Pilar	Bengala	2	1
10	Malteria	Villa Pilar	1	30	Villa Pilar	Malteria	1	2
11	Sultana	La linda	2	31	La linda	Sultana	2	1
12	El Guamal	Villa pilar	2	32	Villa Pilar	El Guamal	2	1
13	Cambulos	Estambul	1	33	Estambul	Cambulos	1	2
14	Aranjuez	Liborio	3	34	Liborio	Aranjuez	3	1
15	Morrogacho	Colinas	3	35	Colinas	Morrogacho	3	1
16	Colinas	Villa Pilar	2	36	Villa Pilar	Colinas	2	1
17	liborio	Enea	3	37	Enea	Liborio	3	3
18	Enea	Villa Pilar	2	38	Enea	Villa Pilar	2	3
19	Enea	Bosques Norte	3	39	Enea	Bosques Norte	3	2
20	La linda	Enea	1	40	La linda	Enea	1	1

La variable “Condición ruta” se basa en el estado actual de la vía por la cual el vehículo de servicio de trasporte público circula, para aplicar técnicas de aumentación de datos se representó la condición de la ruta con el numero “3” si se encuentra en un estado no optimo , el número “2” si es poco optimo y el numero “1” si la ruta esta en optimas condiciones , esto teniendo en cuenta que optimo se da a entender como a una ruta en la cual no se presenta ninguna circunstancia fuera de lo normal ya sea una construcción, cierres programados, o embotellamientos comunes en la ciudad de Manizales a horas pico , entre otros; se hizo una codificación categórica donde primero se convierte la variable categórica “Cond_Ruta” en una variable numérica según la escala como lo muestra la tabla 4.

Tabla 4 : Condicion de la ruta

<i>Cond_Ruta</i>	<i>Estado</i>
<i>No Optima</i>	3
<i>Poco Optima</i>	2
<i>Optima</i>	1

Al convertir la variable "Cond_Ruta" en una variable numérica procedemos a aplicar Data augmentation para aumentar datos de manera efectiva para las rutas específicas, para esto se hace una rotación de las condiciones de rutas existentes. Por ejemplo, para una ruta que originalmente tiene condición "óptima", se roto para representar condiciones "poco óptimas" o "no óptimas", esto significa que cada ruta puede estar contenida en las tres categorías en un determinado momento de tiempo esto tiene relevancia al analizar el sistema de transporte en la ciudad de Manizales ya que en la actualidad al ser una ciudad en expansión una ruta puede variar su estado en lapso corto de tiempo ya sea por construcciones o adecuaciones en la vía.

Una vez que los datos de estudio han sido categorizados, se procede a analizar minuciosamente toda la información disponible. Este proceso comienza centrándose en las variables de ruta, hora, día y condición de la ruta, que sirven como punto de partida para la aplicación de la técnica conocida como "Generación Exhaustiva de Combinaciones". Esta técnica, esencial en la exploración de datos, permite generar todas las combinaciones únicas posibles de los valores de estas variables. Este enfoque detallado ofrece una visión completa y profunda de las diversas situaciones que podrían surgir. Es crucial destacar que cada variable inicialmente abarca todos los valores posibles que podría tomar. Esto se ilustra con claridad en la Tabla 6, donde se pueden apreciar los valores iniciales de cada variable. Este enfoque exhaustivo nos proporciona una base sólida para examinar todas las posibles combinaciones y comprender en profundidad la complejidad de las situaciones que pueden surgir en el contexto del estudio.

<i>Tabla 6: Datos iniciales</i>			
<i>Ruta</i>	<i>Hora</i>	<i>Dia</i>	<i>Cond_Ruta</i>
1	5:00	<i>lunes</i>	<i>optima</i>
2	6:00	<i>martes</i>	<i>poco optima</i>
3	7:00	<i>miercoles</i>	<i>no optima</i>
4	8:00	<i>jueves</i>	
5	9:00	<i>viernes</i>	
6	10:00	<i>sabado</i>	
7	11:00	<i>domingo</i>	
8	12:00		
9	13:00		
10	14:00		
11	15:00		
12	16:00		
13	17:00		
14	18:00		
15	19:00		
16	20:00		
17	21:00		
....	22:00		
32			

Para generar todas las posibles combinaciones de las rutas se utilizaron las bibliotecas de Python “pandas” e “itertools”; utilizando pandas se procede a leer un archivo Excel para luego, obtener todas las posibles combinaciones utilizando `itertools.product()`. Estas combinaciones se almacenan en un DataFrame para luego ser guardadas en un archivo Excel dando a el siguiente proceso que se basa en ingresar en cada ruta su numero de vehículos disponibles, para ello se construye una función llamada “asignar_valor_ruta” que recibe como parámetro el numero de la ruta esto se aprecia en la figura 1.

Figura 1: Función para asignar valores a la columna Vehículos disponibles por ruta

```
# Función para asignar valores a la columna "#Veh_Dis_x_rut" según la ruta
def asignar_valor_ruta(ruta):
    if ruta in [1, 21, 2, 22, 17, 37, 18, 38]:
        return 3
    elif ruta in [6, 26, 10, 20, 13, 33, 19, 39]:
        return 2
    elif ruta in [3, 23, 4, 24, 5, 25, 7, 27, 8, 28, 9, 29, 11, 31, 12, 32, 14, 34, 15, 35, 16, 36, 30, 40]:
        return 1
    else:
        return None
```

De manera similar se procede a ingresar el valor de la demanda que tiene cada ruta teniendo en cuenta que una demanda Alta se representa con un número “3”, media con el numero 2 y baja con el numero 1 para ello se crea una función llamada “asignar_valor_demanda” que recibe también como parámetro la ruta esto se puede apreciar en la figura 2.

Figura 2: Función para asignar valores a la columna demanda

```
# Función para asignar valores a la columna "demanda" según la ruta
def asignar_valor_demanda(ruta):
    if ruta in [1, 21, 6, 26, 14, 34, 15, 35, 17, 37, 19, 39]:
        return 3
    elif ruta in [2, 22, 4, 24, 5, 25, 9, 29, 8, 28, 11, 31, 12, 32, 18, 38]:
        return 2
    elif ruta in [3, 23, 7, 27, 10, 30, 13, 33, 20, 40]:
        return 1
    else:
        return None
```

Después de realizar este procesamiento de la información el data set luce como se puede apreciar en la tabla 7, dando paso a la construcción de las funciones que permitirán llevar todos los datos a su respectiva categoría, con el fin de empezar a llevar a formato numérico toda la información que se ha ido recolectando y procesando a lo largo de la investigación; lo primero que se debe hacer es construir las funciones que permitan categorizar las columnas “Dia, Cond_Ruta” a su respectivo valor. Para esto se construyeron las funciones “asignar_valor_condicion” y “asignar_valor_dia” que reciben como parámetro la condición de la ruta y el día respectivamente como se puede visualizar en la figura 3 y figura 4.

Figura 3: Función “asignar_valor_dia”

```
# Función para asignar valores numéricos a la columna "Dia"
def asignar_valor_dia(dia):
    if dia in ["lunes", "martes", "miércoles", "jueves", "viernes"]:
        return 3
    elif dia in ["sábado", "domingo"]:
        return 1
    else:
        return None
```

Figura 4: Función “asignar_valor_condicion”

```
# Función para asignar valores numéricos a la columna "Cond_Ruta"
def asignar_valor_condicion(condicion):
    if condicion == "no optima":
        return 3
    elif condicion == "poco optima":
        return 2
    elif condicion == "optima":
        return 1
    else:
        return None
```

Tabla 7: Data set despues de los primeros procesamientos

<i>Ruta</i>	<i>Hora</i>	<i>Día</i>	<i>Cond_Ruta</i>	<i>#Veh_Dispatch_rut</i>	<i>demandas</i>
1	05:00	lunes	optima	3	3
1	05:00	lunes	poco optima	3	3
1	05:00	lunes	no optima	3	3
1	05:00	martes	optima	3	3
1	05:00	martes	poco optima	3	3
1	05:00	martes	no optima	3	3
1	05:00	miercoles	optima	3	3
1	05:00	miercoles	poco optima	3	3
1	05:00	miercoles	no optima	3	3
1	05:00	jueves	optima	3	3
1	05:00	jueves	poco optima	3	3
1	05:00	jueves	no optima	3	3
1	05:00	viernes	optima	3	3
1	05:00	viernes	poco optima	3	3
1	05:00	viernes	no optima	3	3
1	05:00	sabado	optima	3	3
1	05:00	sabado	poco optima	3	3

Después de asignar en el data los respectivos valores en sus respectivas columnas se puede empezar a hacer pruebas en la red neuronal

2. Revisión de literatura

Este análisis crítico de estudios y artículos existentes proporciona una base sólida para comprender el contexto y las metodologías que previamente se han utilizado en el campo de la optimización del transporte público. La literatura existente revela que las ciudades de todo el mundo enfrentan desafíos similares en términos de congestión del tráfico, ineficiencias en las rutas de transporte público y la necesidad de gestionar grandes volúmenes de datos generados por estas operaciones. Una tendencia creciente en la investigación se inclina hacia el uso de tecnologías de inteligencia artificial, particularmente redes neuronales, para abordar estos problemas.

Varios estudios han destacado la efectividad de las redes neuronales en la predicción y optimización en el campo del transporte público. Modelos basados en redes neuronales han sido aplicados con éxito para predecir el tiempo de llegada de autobuses, optimizar rutas de transporte y gestionar la demanda de servicios. Estas investigaciones han demostrado mejoras significativas en la eficiencia operativa y la satisfacción del usuario. Sin embargo, a pesar del progreso, existen brechas en la literatura que esta propuesta busca llenar. La especificidad del contexto de Manizales y sus desafíos únicos en términos de topografía y dinámicas de tráfico exigen un enfoque adaptado y localizado. Esta revisión de literatura establece la plataforma para la investigación, resaltando tanto las mejores prácticas como las limitaciones observadas en los estudios previos. A partir de este contexto, la propuesta busca desarrollar una metodología específica para generar predicciones en el sistema de transporte público en Manizales, capitalizando las fortalezas de las redes neuronales y superando las limitaciones previamente identificadas.

2.1 Antecedentes

El uso de técnicas de inteligencia artificial para la optimización de sistemas de transporte público no es un campo sin explorar. Se han realizado varios estudios que utilizan modelos

de redes neuronales para la predicción de variables relevantes en el funcionamiento de estos sistemas, como el flujo de pasajeros, la llegada y salida de buses, el tiempo de espera y la demanda de servicio.

En Singh, V. K., & Kumar, K. (2014). se utilizó una red neuronal para predecir el tiempo de llegada de los autobuses a las paradas. Los autores compararon el modelo propuesto con otros métodos de predicción y encontraron que la red neuronal tenía un mayor nivel de precisión. Esto es de gran relevancia ya que es importante seleccionar el modelo con mayor nivel de precisión, En Wong, A. Y., Zhong, J. H., & Wong, S. C. (2016). se compararon dos modelos de predicción, uno basado en redes neuronales y otro en soporte de regresión de vectores, para predecir el tiempo de llegada de los buses. Los autores encontraron que la red neuronal presentaba una mayor precisión y menor error en las predicciones. Mientras tanto en Singh, V. K., & Kumar, K. (2015). se utilizó una red neuronal para optimizar las rutas de autobuses. Los autores encontraron que el modelo propuesto permitía una reducción en la distancia total recorrida por los autobuses y un aumento en la eficiencia del sistema.

En Zhang, M., Chen, J., & Yu, H. (2017). se propuso un modelo de redes neuronales y regresión de vectores de soporte para predecir la demanda de pasajeros en el sistema de transporte público. Los autores encontraron que el modelo propuesto permitía una mayor precisión en las predicciones en comparación con otros modelos tradicionales. A nivel local se tiene que

Leal García, L. (2014). Realizo un proyecto que habla sobre que en la actualidad el servicio de transporte se presta de mala calidad, debido al atraso tecnológico en el sistema, falta de cobertura y accesibilidad, falta de mecanismos efectivo de recaudo, falta de control de flota y deficiencias en la infraestructura del transporte, generando tiempos de viaje elevados, sobrecostos operacionales, baja cobertura en el servicio e insatisfacción del usuario del transporte. Se propone implementar un sistema estratégico de transporte público colectivo SETP basadas en sistemas centralizados, con medios de pago electrónico; servicios de transporte colectivo integrados y accesibles para la población en radio de acción. Y García Campino, R. (2008). Propusieron tres rutas adicionales para el nuevo sistema de transporte público colectivo urbano de la ciudad de Manizales, dichas rutas se determinaron a partir de un análisis minucioso sobre la matriz de origen y destino para la ciudad

de Manizales elaborada por la Universidad Nacional De Colombia y actualizada según la información presentada por la Universidad y la consultada en el DANE, teniendo en cuenta los posibles sectores que no están cubiertos en su totalidad por el sistema de rutas reestructurado

3. Desarrollo

3.1 Marco conceptual

Una red neuronal es un modelo matemático y computacional inspirado en la estructura y el funcionamiento del cerebro humano. Se utiliza para realizar tareas que implican aprendizaje y reconocimiento de patrones. Estas redes están compuestas por nodos (neuronas) interconectados que trabajan en conjunto para resolver problemas complejos. Cada conexión entre neuronas tiene un peso asociado. Estos pesos determinan la fuerza de la influencia de una neurona sobre otra. Durante el entrenamiento, los pesos se ajustan para mejorar el rendimiento de la red. Cada neurona tiene una función de activación que determina si se activa o no en función de las señales recibidas. Algunas funciones comunes incluyen la función sigmoide, la función de paso y la función ReLU (Rectified Linear Unit). Las neuronas se organizan en capas. Las redes neuronales suelen tener una capa de entrada, una o varias capas ocultas y una capa de salida. Las capas ocultas son responsables de aprender patrones complejos en los datos, en una capa pueden estar conectadas a todas las neuronas en la capa siguiente. Las conexiones entre neuronas tienen pesos que se ajustan durante el entrenamiento. Las redes neuronales aprenden ajustando los pesos de las conexiones durante el entrenamiento. Utilizan algoritmos como "retro propagación" (backpropagation) para minimizar la diferencia entre las predicciones de la red y las salidas deseadas.

Entrenar una red neuronal implica ajustar los pesos y sesgos de la red para que pueda realizar una tarea específica correctamente. En el contexto del aprendizaje supervisado, esto significa que la red neuronal aprende a mapear entradas a salidas deseadas, basándose en un conjunto de datos de entrenamiento donde las entradas y las salidas ya están emparejadas. Normalmente al principio los pesos de la red se inicializan aleatoriamente. Estos pesos determinan la influencia de las conexiones entre las neuronas. Durante la propagación hacia adelante (Forward Propagation), las entradas se

pasan a través de la red, y cada neurona realiza cálculos basados en los pesos y las funciones de activación. Esto genera una predicción. En este proceso se puede presentar un porcentaje de pérdida. La pérdida (o error) se calcula comparando la predicción de la red con la salida esperada en el conjunto de entrenamiento. Existen diversas funciones de pérdida según el tipo de problema (por ejemplo, para problemas de clasificación se usa la entropía cruzada); Una vez que se calcula la pérdida, se da inicio a la retro propagación del Error (Backpropagation) se retro propaga hacia atrás a través de la red. Durante este proceso, se calculan las derivadas parciales de la función de pérdida con respecto a los pesos de la red. Esto indica cómo deben ajustarse los pesos para reducir la pérdida. Al obtener las derivadas, se utiliza un algoritmo de optimización (como el descenso del gradiente) para ajustar los pesos y minimizar la pérdida. El tamaño del paso de ajuste (conocido como tasa de aprendizaje) es un parámetro crítico en este proceso ya que una tasa de aprendizaje adecuada permite que el modelo converja más rápido hacia una solución óptima. Una tasa de aprendizaje demasiado pequeña hará que el proceso de aprendizaje sea lento, mientras que una tasa demasiado grande puede hacer que el modelo oscile alrededor de la solución óptima sin converger. Este proceso se puede repetir iterativamente durante varias épocas o hasta que la pérdida converja a un valor mínimo aceptable en el conjunto de entrenamiento.

Después de entrenar la red, se evalúa su rendimiento en un conjunto de datos de validación para asegurarse de que no se ha sobre ajustado al conjunto de entrenamiento. En caso de sobreajuste (cuando el modelo se adapta demasiado a los datos de entrenamiento y no puede generalizar bien), se pueden tomar medidas para regularizar la red (por ejemplo, mediante la técnica de abandono o dropout). Es por ello que definir una tasa de aprendizaje adecuada resulta crucial para el proceso, ya que al estar equilibrada puede ayudar a mantener la estabilidad del entrenamiento si es Demasiado alta los pesos pueden oscilar y nunca converger. Si es Demasiado baja el modelo puede quedarse atascado en un mínimo local o incluso puede no aprender nada; El objetivo del entrenamiento de una red neuronal es aprender patrones en los datos que sean generalizables, y no vistos antes, con el fin de dar paso a el proceso de pruebas y evaluación que consiste en evaluar el modelo entrenado utilizando datos que no ha visto antes (conjunto de prueba). Este paso es crucial para determinar el rendimiento real del modelo en datos no vistos y verificar si generaliza bien.

Si el rendimiento del modelo en el conjunto de prueba no es satisfactorio, se debe considerar ajustar los hiperparámetros, como la tasa de aprendizaje, el número de capas, el número de neuronas, etc., y luego volver a entrenar el modelo. Debido a que es un proceso iterativo. A menudo, es necesario ajustar el modelo y los datos en función de los resultados obtenidos durante la evaluación para mejorar el rendimiento del modelo en datos no vistos y garantizar una mejor generalización. Este proceso se puede repetir durante varias épocas o hasta que la pérdida converja a un valor mínimo aceptable en el conjunto de entrenamiento.

El problema principal que se encuentra a la hora de entrenar una red neuronal se basa en la cantidad de datos de entrenamiento que tenemos a nuestro alcance, que estén correctamente etiquetados y limpios, en el caso de estudio actual conseguir todos estos datos no resulta un proceso fácil ya que las empresas de transporte público de Manizales no resultan muchas veces flexibles a la hora de difundir información de sus operaciones; la búsqueda de la información puede resultar costosa y tardada, es por eso se han propuesto técnicas que facilitan la recolección y procesamiento de la información como la Transfer Learning (Transferencia de Aprendizaje) o “Data Augmentation”, técnicas en las cuales se busca tener un mayor número de datos con el fin de que las predicciones que genere sean más acertadas y tengan un bajo porcentaje de error, para este trabajo de grado se tendrán en cuenta variables de relevancia como lo son: la ruta específica que recorren los vehículos de servicio de transporte público, las condiciones en que se encuentra la ruta (optima o no), los vehículos disponibles con los que cuentan para cubrir la ruta, la hora , el día de la semana; dado que en la actualidad en la ciudad de Manizales no se cuenta aún con el servicio de Tarjetas de Chip Inteligente que le permita a el usuario recargar crédito en el chip de la tarjeta, y los lectores de tarjetas puedan leer la información del chip para procesar el pago generando así un registro en la base de datos de las empresas de transporte público no se dispone de esta valiosa información.

Teniendo en cuenta lo anterior se planea utilizar la técnica “Data Augmentation” que es utilizada en el campo del aprendizaje profundo (y específicamente en problemas de visión por computadora) para aumentar la cantidad y variedad de datos de entrenamiento. Implica aplicar transformaciones simples y aleatorias a los datos existentes para crear nuevas muestras de datos. Estas transformaciones no cambian la etiqueta o la naturaleza

fundamental de la muestra, pero sí alteran su apariencia de maneras que son realistas y relevantes para el problema que se está abordando, La Data Augmentation se utiliza principalmente cuando el conjunto de datos de entrenamiento es limitado, lo que es bastante común en situaciones del mundo real. Al aumentar artificialmente el tamaño del conjunto de datos, se puede mejorar la capacidad del modelo para generalizar a datos nuevos y no vistos. Además, al exponer el modelo a una variedad de transformaciones de los datos, se hace más robusto frente a las variaciones en los datos de prueba, las transformaciones pueden implicar cambiar palabras por sinónimos, reorganizar oraciones, variar rangos de hora, entre otros.

3.1.1 Definición de Conceptos Clave

OVERFITTING

Las principales causas al obtener malos resultados en Machine Learning son el overfitting o el underfitting de los datos. Cuando entrenamos nuestro modelo intentamos “hacer encajar” -fit en inglés- los datos de entrada entre ellos y con la salida. Tal vez se pueda traducir overfitting como “sobreajuste” y underfitting como “subajuste” y hacen referencia al fallo de un modelo al generalizar -encajar- el conocimiento que se pretende que adquieran. Para entrenar una red neuronal con pocos datos de entrenamiento, se analizan diferentes modelos existentes que ya han sido entrenados en una tarea similar, de manera que en primera instancia se tendrá una red neuronal que ya tiene claro lo que se supone que debe hacer y se deberá adaptar de manera que cumpla con las necesidades principales del problema planteado” aprendemachinelearning. (2017).

Función de activación:

En el contexto de redes neuronales, una función de activación es una función matemática que determina la salida de una neurona. Introduce no linealidad en la red, lo que permite que la red aprenda patrones complejos en los datos; Las funciones de activación son funciones matemáticas que se utilizan en las redes neuronales artificiales para introducir no linealidad en el modelo. Sin estas funciones, la red se comportaría como una única capa

lineal, sin importar el número de capas, lo que limitaría su capacidad para aprender patrones complejos en los datos. Medium (2017).

Backpropagation:

"Backpropagation es un algoritmo de optimización que calcula el gradiente de una función de costo con respecto a los pesos de una red neuronal. Utiliza este gradiente para actualizar iterativamente los pesos de la red, de modo que la función de costo se minimice y la red pueda hacer predicciones más precisas." Stanford University (2023).

Tasa de aprendizaje (ETA):

La tasa de aprendizaje es un hiperparámetro crítico en el entrenamiento de redes neuronales. Es un factor de escala que determina el tamaño de los pasos que se toman durante la optimización. Una tasa de aprendizaje adecuada es esencial para garantizar que el modelo converja de manera eficiente y produzca resultados precisos. Machine Learning Mastery (2020)

Hiperparámetros:

"Los hiperparámetros son configuraciones que se establecen antes de entrenar un modelo de aprendizaje automático y no se modifican durante el entrenamiento. Son esenciales para definir la arquitectura y el comportamiento del modelo, y su ajuste cuidadoso puede mejorar significativamente el rendimiento del modelo." -: Towards Data Science (2020).

Aprendizaje Profundo:

"El aprendizaje profundo es una técnica de aprendizaje automático que utiliza redes neuronales con múltiples capas para aprender representaciones jerárquicas de datos. Estas representaciones permiten que el modelo capture patrones complejos y realice tareas sofisticadas, como reconocimiento de voz, traducción automática y reconocimiento de imágenes." MIT Technology (2013).

Interpolación

La interpolación es el proceso de estimar valores desconocidos dentro de un rango de valores conocidos. En matemáticas y estadísticas, se utiliza para aproximar funciones y datos incompletos. La interpolación se basa en la idea de que los valores entre puntos

conocidos pueden estimarse utilizando métodos matemáticos, como polinomios o splines. Meijering, E (2002).

Rotación temporal

La rotación temporal se refiere al ajuste de las características temporales, como el tiempo o las secuencias temporales, en un conjunto de datos. En el contexto de la manipulación de datos temporales, la rotación temporal implica cambiar o ajustar las marcas de tiempo para crear variaciones en los datos temporales.

Codificación Categórica

La codificación categórica es el proceso de convertir variables categóricas en una forma que los algoritmos de aprendizaje automático puedan entender. Es crucial para trabajar con datos categóricos en algoritmos de aprendizaje automático, ya que muchos algoritmos requieren variables numéricas como entrada. a." Towards Data Science (2019).

4. Conclusiones y recomendaciones

4.1 Conclusiones

Las conclusiones constituyen un capítulo independiente y presentan, en forma lógica, los resultados del trabajo. Las conclusiones deben ser la respuesta a los objetivos o propósitos planteados. Se deben titular con la palabra conclusiones en el mismo formato de los títulos de los capítulos anteriores (Títulos primer nivel), precedida por el numeral correspondiente (según la presente plantilla).

4.2 Recomendaciones

Se presentan como una serie de aspectos que se podrían realizar en un futuro para emprender trabajos similares o fortalecer el trabajo realizado.

A. Anexo: Nombrar el anexo A de acuerdo con su contenido

Los Anexos son documentos o elementos que complementan el cuerpo del trabajo y que se relacionan, directa o indirectamente, con la investigación, tales como acetatos, cd, normas, etc. Los anexos deben ir numerados con letras y usando el estilo “Título anexos”.

Bibliografía

La bibliografía es la relación de las fuentes documentales consultadas por el autor para sustentar sus trabajos. Su inclusión es obligatoria en todo trabajo de grado. Cada referencia bibliográfica se inicia contra el margen izquierdo.

Bajo la Resolución 023 de 2015. Artículo 2. Parágrafo 1.

La plantilla no especifica la norma bibliográfica que se debe utilizar. Se brindará la libertad para aplicar la norma para el manejo de las referencias bibliográficas, de acuerdo con el estándar de cada área del conocimiento, siempre y cuando ésta se aplique con rigurosidad.

Se recomienda el uso de gestores bibliográficos como Mendeley, Zotero, etc. A continuación, se lista algunas instituciones que brindan parámetros para el manejo de las referencias bibliográficas:

Ejemplo Referencias bibliográficas

Institución	Disciplina de aplicación	Vínculos y ejemplos
AMA (Asociación Médica de los Estados Unidos)	Ambito de la salud (psicología, medicina)	HealthLinks.Washington.edu/hsl/StyleGuides/AMA.htm (manual de estilo de la AMA, que sirve de estándar para las disciplinas que se ocupan de medicina, salud y ciencias biológicas). Liunet.edu/Cwis/Cwp/Library/Workshop/CitAMA.htm (ejemplos).
American Psychological Association (APA)	Ambito de la salud (psicología, medicina) y en general en todas las ciencias sociales.	APAStyle.org. Biblioteca.udg.es/Info_General/Guies/Cites/Citar_Llibre s.asp (reglamento). Liunet.edu/Cwis/Cwp/Library/Workshop/Citapa.htm (ejemplos).
Harvard System of Referencing Guide	Todas las disciplinas	Disponibles en: http://libweb.anglia.ac.uk/referencing/harvard.htm
JabRef y KBibTeX	Todas las disciplinas	Herramientas de LaTeX para la gestión de referencias bibliográficas.

(continúa)

Ejemplo Referencias bibliográficas (continuación)

Institución	Disciplina de aplicación	Vínculos y ejemplos
Manual	Todas las disciplinas	Patrias, K.: National Library of Medicine recommended formats for bibliographic citation. Bethesda (Maryland, EE. UU.): National Library of Medicine (Reference Section), 1991.
Modern Language Association (MLA)	Literatura, artes y humanidades.	MLA.org Biblioteca.udg.es/Info_General/Guies/Cites/MLA.asp (reglamento). Liunet.edu/Cwis/Cwp/Library/Workshop/CitMLA.htm Ejemplos
National Library of Medicine (NLM) (Biblioteca Nacional de Medicina)	En el ámbito médico y, por extensión, en ciencias.	NLM.NIH.gov NLM.NIH.gov/Pubs/Formats/RecommendedFormats.html (formatos recomendados)
Universidad de Chicago/Turabian	Periodismo, historia y humanidades.	ChicagoManualOfStyle.org BedfordStMartins.com/Hacker/Resdoc/History/Footnotes.htm (Reglamento I) o BedfordStMartins.com/Online/Cite7.html (Reglamento II). liunet.edu/cwis/cwp/library/workshop/citchi.htm (ejemplos de la universidad de Chicago) liunet.edu/cwis/cwp/library/workshop/citchi.htm Liunet.edu/Cwis/Cwp/Library/Workshop/Citchi.htm (ejemplos de las reglas de Turabian)
Vancouver	Todas las disciplinas	Fisterra.com/Recursos_Web/Mbe/Vancouver.asp (estilo de Vancouver 2000).

Singh, V. K., & Kumar, K. (2014). "Prediction of bus arrival time using artificial neural networks";

Wong, A. Y., Zhong, J. H., & Wong, S. C. (2016). "Predictive models for bus arrival time using artificial neural network and support vector regression".

Singh, V. K., & Kumar, K. (2015). "Optimization of bus routes using a neural network approach."

Zhang, M., Chen, J., & Yu, H. (2017). "A bus Passenger demand forecasting model using artificial neural networks and support vector regression."

Leal Garcia, L. (2014). "Implementación Sistema Estratégico de Transporte Manizales, Caldas, Occidente.";

García Campino, R. (2008). Análisis de nuevas rutas en el sistema de transporte público colectivo urbano de la ciudad de Manizales

aprendemachinelearning. (2017) "Qué es overfitting y underfitting y cómo solucionarlo". (buscar modelos de redes neuronales que ya trabajaron en el tema

<https://computerhoy.com/apps/como-saben-google-maps-waze-hay-atasco-carretera-1291882> como trabaja waze

<https://medium.com/the-theory-of-everything/understanding-activation-functions-in-neural-networks-9491262884e0>

<http://cs231n.stanford.edu/>

<https://mathworld.wolfram.com/Interpolation.html>

<https://www.technologyreview.com/technology/deep-learning/>

<https://towardsdatascience.com/parameters-and-hyperparameters-aa609601a9ac>

<https://machinelearningmastery.com/understand-the-dynamics-of-learning-rate-on-deep-learning-neural-networks/>

<https://towardsdatascience.com/categorical-encoding-using-label-encoding-and-one-hot-encoder-911ef77fb5bd>